



Document de Recommandations

Évolution vers un Mode IA pour un Moteur de Recherche basé sur Elasticsearch

1. Contexte

Le système actuel dispose déjà d'une architecture avancée comprenant :

- Recherche hybride (BM25 + vector search)
- Base de données centralisée
- Analyse d'intention via un modèle de Machine Learning
- Elasticsearch comme moteur principal

Objectif : Ajouter un **mode IA (AI Answer Mode)** permettant de générer des réponses intelligentes, contextualisées et personnalisées, à la manière des moteurs modernes.

2. Vision cible

Passer d'un moteur de recherche classique à un :

Système hybride Search + Answer Engine (RAG avancé)

Le système doit être capable de :

- Comprendre l'intention utilisateur
 - Extraire les données pertinentes
 - Générer une réponse naturelle
 - Justifier les réponses avec les sources
-

3. Architecture recommandée

Pipeline global

User Query

→ Intent Detection

→ Elasticsearch (Hybrid Search)

→ Top-K Documents

→ Re-ranking

→ Context Builder

→ LLM

→ Réponse + Sources

4. Composants à ajouter

4.1 Answer Orchestrator (Composant clé)

Responsabilités :

- Piloter le pipeline
 - Adapter le traitement selon l'intention
 - Gérer la construction du contexte
 - Interagir avec le LLM
-

4.2 Context Builder avancé

Rôle critique : transformer les résultats Elasticsearch en contexte exploitable.

Recommandations :

- Limiter à Top 5-10 résultats
 - Structurer les données (titre, description, score, métadonnées)
 - Ajouter une justification de pertinence
 - Convertir en format texte structuré
-

4.3 Prompt Engineering dynamique

Adapter les prompts selon l'intention :

- Information → Résumé
- Recommandation → Classement + explication
- Navigation → Résultats directs

Contraintes à inclure :

- Interdiction d'inventer
 - Réponse basée uniquement sur les données
 - Gestion des cas d'insuffisance d'information
-

4.4 LLM (modèle open source)

Recommandations :

- Modèles compacts pour performance (exécution locale ou API)
 - Versions quantisées si ressources limitées
-

4.5 Re-ranking avancé

Ajouter une étape de re-ranking après Elasticsearch :

Objectif :

- Améliorer la pertinence
- Réduire le bruit

Méthodes :

- Cross-encoder
 - Scoring basé LLM
-

5. Fonctionnalités à implémenter

5.1 Mode IA (AI Answer Mode)

- Génération de réponse synthétique
 - Affichage des sources
 - Interface distincte du mode classique
-

5.2 Query Rewriting

- Reformulation automatique des requêtes
 - Enrichissement sémantique
-

5.3 Réponses avec sources

Toujours retourner :

- Réponse générée
 - Documents Elasticsearch utilisés
-

5.4 Personnalisation (optionnel)

- Historique utilisateur
 - Préférences
-

5.5 Mode conversationnel (avancé)

- Mémoire des interactions
 - Suivi du contexte
-

6. Bonnes pratiques

- Limiter le contexte envoyé au modèle
 - Éviter les données brutes
 - Structurer les informations
 - Tester différents prompts
 - Monitorer les réponses
-

7. Risques et mitigation

Hallucinations

→ Prompt strict + données contrôlées

Latence

→ Limiter Top-K + modèles optimisés

Coût

→ Modèles locaux ou quantisés

Pertinence

→ Re-ranking + amélioration du contexte

8. Roadmap recommandée

Phase 1

- Implémentation RAG simple

- Génération de réponses

Phase 2

- Prompt dynamique
- Context builder avancé

Phase 3

- Re-ranking IA
- Query rewriting

Phase 4

- Personnalisation
 - Mode conversationnel
-

9. Conclusion

Le système actuel est déjà très avancé. L'évolution vers un mode IA ne nécessite pas une refonte, mais une **couche d'orchestration intelligente**.

Le facteur clé de succès ne sera pas le modèle utilisé, mais :

- La qualité du contexte
 - La logique d'orchestration
 - L'adaptation à l'intention utilisateur
-

10. Prochaine étape

Mettre en place un prototype d'Answer Engine connecté à Elasticsearch, avec :

- Top-K retrieval
- Context structuré
- Prompt contrôlé
- Génération LLM

Puis itérer progressivement.

Fin du document